



LUDWIG-
MAXIMILIANS-
UNIVERSITÄT
MÜNCHEN

INSTITUT FÜR INFORMATIK

LEHRSTUHL FÜR MOBILE UND VERTEILTE SYSTEME

SEMINAR CURRAI

Symmetry as a Design Axis in Variational Quantum Learning

BEARBEITER: Markus Baumann

BETREUER: Jonas Stein

AUFGABENSTELLER: Prof. Dr. Claudia Linnhoff-Popien

Dokument erstellt
31. Mai 2026



Symmetry as a Design Axis in Variational Quantum Learning

Zusammenfassung

Diese Arbeit untersucht Symmetrie als induktiven Bias in Variational Quantum Learning. Ausgangspunkt ist Meyer et al., die zeigen, dass ein D_4 -äquivalentes Tic-Tac-Toe-Modell besser generalisieren kann als ein unbeschränktes Modell. Die Arbeit rekonstruiert diese Idee, erweitert sie aber um zwei experimentelle Fragen: Erstens wird die volle Symmetrie nicht nur gegen keine Symmetrie, sondern gegen Untergruppen wie C_4 , D_2 und Z_2 verglichen. Zweitens wird untersucht, ob die größte Verbesserung nicht durch mehr oder weniger Symmetrie, sondern durch eine besser zur Aufgabe passende äquivalente Gate-Struktur entsteht. Dazu werden die ursprünglichen gerichteten Edge-Interaktionen um trainierbare Winning-Line-Gates auf den acht Gewinnlinien des Spielfelds erweitert. Die finalen 10-Seed-Experimente reproduzieren den Meyer-artigen Generalisierungseffekt: D_4 verbessert die Test Accuracy gegenüber keiner Symmetrie und reduziert den Generalization Gap. Partielle Symmetrie, insbesondere C_4 , erreicht fast dieselbe Leistung wie D_4 , schlägt es aber nicht robust. Der stärkste empirische Effekt kommt von task-aligned equivariant gates: ein D_4 -äquivalentes Edge-plus-Line-Modell erreicht bei 600 Trainingsbeispielen etwa 0.785 Test Accuracy gegenüber etwa 0.687 für den Meyer-artigen Edge-Ansatz. Parameter-matched random sharing zeigt, dass der Effekt nicht bloß durch weniger Parameter erklärt wird. Die Schlussfolgerung ist konservativ: Die Arbeit behauptet keinen Quantum Advantage, sondern zeigt an einem kontrollierten Benchmark, dass Äquivarianz nicht nur als harte Constraint, sondern als Architekturprinzip verstanden werden sollte.

Inhaltsverzeichnis

1	Einleitung	1
2	Theoretischer Hintergrund	2
2.1	Variational Quantum Learning Models	2
2.2	Von Datensymmetrien zu Hilbert-Raum-Repräsentationen	2
2.3	Gate Symmetrization und Parameter-Sharing	3
3	Vom Originalpaper zur eigenen Fragestellung	3
3.1	Was Meyer et al. zeigen	3
3.2	Research Question	3
3.3	Designraum	4

4	Experimentelles Protokoll	5
4.1	Datensatz und Labels	5
4.2	Schaltkreis	5
4.3	Untergruppen und Parameterzahlen	5
4.4	Winning-Line-Gates	6
5	Ergebnisse	6
5.1	Reproduktion: volle Symmetrie generalisiert besser	6
5.2	Partielle Äquivarianz: C_4 ist konkurrenzfähig, aber kein robuster Sieger	7
5.3	Random-Sharing-Control: Nicht nur weniger Parameter	8
5.4	Task-Aligned Equivariant Gates: der stärkste Effekt	8
5.5	Deterministischer Oracle als Sanity Check	9
6	Diskussion	9
6.1	Symmetrie als Designachse	9
6.2	Symmetrie ist nicht gleich Parameterreduktion	9
6.3	Warum Winning-Line-Gates sinnvoll sind	10
6.4	Grenzen der Ergebnisse	10
6.5	Soft Symmetry als Ausblick	10
7	Fazit	11
	Formale Angaben	12
	Literatur	14

1 Einleitung

Symmetrie ist einer der wenigen induktiven Biases, die gleichzeitig mathematisch präzise, architektonisch umsetzbar und empirisch überprüfbar sind. Wenn eine Lernaufgabe invariant gegenüber einer Transformation ist, sollte ein Modell diese Invarianz nicht erst aus endlich vielen Daten lernen müssen. Bei Bildern führt diese Idee zu Faltungen und gruppenäquivalenten Netzen [5, 4]; bei Mengen führt sie zu permutationsinvarianten Architekturen wie Deep Sets [12]; im allgemeineren geometrischen Deep Learning wird sie als Grundprinzip formuliert, Datenräume, Gruppenwirkungen und Modellklassen gemeinsam zu betrachten [3].

Für Variational Quantum Machine Learning ist diese Perspektive besonders relevant. Variational Quantum Learning Models (VQLMs) bestehen aus parametrisierten Quantenschaltkreisen, deren Erwartungswerte als Vorhersagen interpretiert werden [1, 11]. Sie sind flexibel, aber diese Flexibilität ist ambivalent. Auf NISQ-Geräten sind Schaltkreistiefe, Messstatistik und Rauschen begrenzt [10, 2]. Zudem kann hohe Expressivität die Optimierung erschweren und Generalisierung verschlechtern [6, 9]. Ein sinnvoller architektonischer Bias ist deshalb nicht nur ästhetisch, sondern praktisch notwendig.

Der Ausgangspunkt dieser Arbeit ist das Paper *Exploiting symmetry in variational quantum machine learning* von Meyer et al. [7]. Die Autoren zeigen, wie eine bekannte Datensymmetrie in ein VQLM eingebaut werden kann. Im Tic-Tac-Toe-Beispiel ist das Label invariant unter den acht Rotationen und Spiegelungen des Spielfelds, also unter der Diedergruppe D_4 . Meyer et al. konstruieren ein Modell, dessen Vorhersage diese Symmetrie per Konstruktion respektiert, und zeigen qualitativ, dass das symmetrische Modell besser generalisieren kann als ein unbeschränktes Modell.

Diese Arbeit übernimmt diese Idee, verschiebt aber die Fragestellung. Meyer et al. beantworten die Frage, ob volle Symmetrie gegenüber keiner Symmetrie helfen kann. Die natürliche Anschlussfrage lautet: Ist die volle Symmetrie bereits das Ende des Designraums? Oder kann man innerhalb der Klasse symmetrieverträglicher Modelle noch bessere Architekturen bauen? Genau hier liegt der Beitrag dieser Arbeit. Symmetrie wird nicht nur als Ja-Nein-Entscheidung verstanden, sondern als Architekturprinzip mit mehreren Freiheitsgraden.

Wir untersuchen drei Ebenen. Erstens reproduzieren wir den Meyer-artigen Effekt auf dem Tic-Tac-Toe-Benchmark: Ein D_4 -äquivalentes Modell generalisiert besser als ein Modell ohne Parameter-Sharing. Zweitens ersetzen wir die binäre Gegenüberstellung von *none* und D_4 durch eine Familie von Untergruppenmodellen: Z_2 -Rotation, Z_2 -Spiegelung, C_4 , D_2 und volles D_4 . Dadurch wird partielle Äquivarianz als diskreter Regler zwischen Expressivität und induktivem Bias sichtbar. Drittens führen wir task-aligned equivariant gates ein: trainierbare Gates auf den acht Gewinnlinien des Tic-Tac-Toe-Felds. Diese Gates brechen die Symmetrie nicht, sondern respektieren sie über dasselbe Orbit-Sharing. Sie geben dem Schaltkreis aber direkten Zugriff auf die dreizehligen Motive, aus denen das Label berechnet wird.

Die wichtigsten Ergebnisse sind konservativ, aber klar. Die Reproduktion bestätigt die Richtung von Meyer et al.: Bei Trainingsgröße 600 erreicht das unbeschränkte Edge-Modell 0.627 ± 0.013 Test Accuracy, während das D_4 -äquivalente Edge-Modell 0.687 ± 0.020 erreicht. Der Generalization Gap sinkt von 0.070 auf 0.021. Die partielle Symmetrie C_4 erreicht fast dieselbe Leistung wie D_4 und liegt in einzelnen Regimen leicht vorn, aber nicht robust genug für den Claim, dass weniger Symmetrie grundsätzlich besser sei. Der stärkste Effekt entsteht durch die winning-line gates: Das beste D_4 -äquivalente Edge-plus-Line-Modell erreicht bei 600 Trainingsbeispielen 0.785 ± 0.021 Test Accuracy, also deutlich mehr als der Meyer-artige Edge-Ansatz mit 0.687 ± 0.020 .

Die Arbeit behauptet keinen Quantum Advantage. Tic-Tac-Toe ist klassisch trivial; ein deterministischer Regel-Oracle erreicht auf allen 5478 legalen Zuständen 100% Genauigkeit mit null trainierbaren Parametern. Gerade deshalb ist der Benchmark nützlich: Er erlaubt eine kontrollierte Untersuchung, ob ein VQLM die bekannte Struktur sinnvoll nutzt. Die wissenschaftliche Aussage ist nicht, dass ein Quantenmodell Tic-Tac-Toe besonders gut löst. Die Aussage ist, dass Äquivalenz in VQLMs nicht nur eine Parameterreduktion ist, sondern ein Designprinzip dafür, welche trainierbaren Interaktionen überhaupt angeboten werden sollten.

2 Theoretischer Hintergrund

2.1 Variational Quantum Learning Models

Ein VQLM kodiert klassische Daten x in einen Quantenzustand, verarbeitet diesen Zustand mit trainierbaren Gates und liest Erwartungswerte von Observablen aus. Eine typische Vorhersage hat die Form

$$f_\theta(x) = \langle 0 | U_\theta^\dagger(x) O U_\theta(x) | 0 \rangle, \quad (1)$$

wobei O ein Observable und $U_\theta(x)$ ein datenabhängiger parametrisierter Schaltkreis ist. In Data-Reuploading-Modellen wird dasselbe Daten-Encoding mehrfach in den Schaltkreis eingebracht [8]. Dadurch kann das Modell nichtlineare Funktionen der Eingabe darstellen. Eine typische Form ist

$$U_\theta(x) = W_L(\theta) U(x) \cdots W_1(\theta) U(x), \quad (2)$$

wobei $U(x)$ das Daten-Encoding und $W_\ell(\theta)$ trainierbare Blöcke sind.

Die zentrale Designfrage ist nicht nur, wie viele Parameter ein solcher Schaltkreis hat. Entscheidend ist, welche Funktionen durch Encoding, Gates und Messung erreichbar sind. Symmetrie wirkt genau auf diese Funktionsklasse. Wenn ein Modell invariant unter einer Gruppe G sein soll, gilt

$$f_\theta(gx) = f_\theta(x) \quad \text{für alle } g \in G. \quad (3)$$

Ein Modell, das diese Gleichheit per Konstruktion erfüllt, muss sie nicht aus Daten lernen. Das ist besonders in Low-Data-Regimen relevant.

2.2 Von Datensymmetrien zu Hilbert-Raum-Repräsentationen

Meyer et al. formulieren die Symmetriebedingung über eine kompatible Darstellung im Hilbert-Raum [7]. Eine Datentransformation g soll durch einen unitären Operator U_g so dargestellt werden, dass

$$U(gx) = U_g U(x) U_g^\dagger. \quad (4)$$

Wenn zusätzlich der Startzustand und das Observable invariant sind und die trainierbaren Blöcke mit allen U_g kompatibel sind, folgt die Invarianz der Vorhersage.

Im Tic-Tac-Toe-Beispiel ist diese Bedingung anschaulich. Jedes der neun Spielfeldfelder wird einem Qubit zugeordnet. Eine Rotation oder Spiegelung des Spielfelds ist dann eine Permutation der Qubits. Die Diedergruppe D_4 enthält acht Transformationen: Identität, Rotationen um 90° , 180° und 270° , sowie vier Spiegelungen. Ecken werden auf Ecken abgebildet, Kanten auf Kanten, und das Zentrum bleibt Zentrum. Dadurch entstehen natürliche Orbits im Schaltkreis.

2.3 Gate Symmetrization und Parameter-Sharing

Meyer et al. beschreiben Gate Symmetrization über Twirling. Ein Gate

$$R_G(\theta) = \exp(-i\theta G) \quad (5)$$

ist symmetrieverträglich, wenn sein Generator G mit der Gruppenrepräsentation kommutiert. Aus einem beliebigen Generator kann durch

$$\Pi_{\text{sym}}(G) = \frac{1}{|G|} \sum_{g \in G} U_g G U_g^\dagger \quad (6)$$

ein symmetrischer Anteil gewonnen werden. In unserer Implementierung verwenden wir für den Tic-Tac-Toe-Ansatz eine äquivalente und transparente Sicht: Parameter werden entlang der Orbits der Gruppe geteilt. Alle Qubits oder gerichteten Gate-Paare, die durch eine Symmetrie ineinander überführt werden, erhalten denselben trainierbaren Parameter.

Für volles D_4 bedeutet das zum Beispiel: alle vier Ecken teilen Parameter, alle vier Kanten teilen Parameter, und das Zentrum bleibt ein eigener Orbit. Für eine kleinere Untergruppe wie C_4 werden nur Rotationen erzwungen; Spiegelungen müssen nicht identisch behandelt werden. Damit entsteht ein diskreter Bias-Expressivitäts-Regler. Größere Untergruppen erzwingen mehr Gleichheiten und reduzieren die Zahl trainierbarer Parameter. Kleinere Untergruppen erlauben mehr Ausdruckskraft, verlieren aber einen Teil des induktiven Bias.

3 Vom Originalpaper zur eigenen Fragestellung

3.1 Was Meyer et al. zeigen

Das Originalpaper zeigt, dass Symmetrie in VQLMs nicht nur nachträglich als Regularisierung formuliert werden muss, sondern direkt in den Schaltkreis eingebaut werden kann [7]. Am Tic-Tac-Toe-Benchmark ist die zentrale qualitative Beobachtung: Ein symmetrisches Modell kann eine niedrigere oder ähnliche Trainingsleistung haben, aber besser testen. Das freie Modell hat mehr Freiheitsgrade und kann Trainingsdaten stärker ausnutzen; das symmetrische Modell beschränkt sich auf Funktionen, die zur Aufgabenstruktur passen.

Diese Aussage ist wissenschaftlich sauber, aber sie lässt eine Anschlussfrage offen. Das Originalpaper behandelt Symmetrie im Tic-Tac-Toe-Beispiel im Wesentlichen als volle Task-Symmetrie. Sobald D_4 bekannt ist, liegt es nahe, die ganze Gruppe zu erzwingen. Aus Sicht der Modellarchitektur ist das aber nicht die einzige mögliche Entscheidung. Man kann Untergruppen erzwingen, Parameter randomisiert teilen, zusätzliche äquivariante Gates einbauen oder die Symmetrie nur als Loss-Regularisierung verwenden. Die interessante Frage ist daher nicht nur: *Hilft Symmetrie?* Sondern: *Welche symmetrieverträgliche Architektur hilft?*

3.2 Research Question

Die Arbeit untersucht die Frage:

Ist volle D_4 -Äquivarianz die beste praktische Induktionsannahme im Tic-Tac-Toe-VQLM? Oder kann man durch partielle Symmetrie und task-aligned equivariant gates bessere Generalisierung erreichen?




Abbildung 1: Designraum der Arbeit. Tic-Tac-Toe-Labels sind invariant unter den acht Rotationen und Spiegelungen des Bretts. Die Brettwerte werden auf neun Qubits kodiert, und Untergruppen erzeugen unterschiedliche Parameter-Sharing-Orbits. Der Meyer-artige Edge-Ansatz nutzt orbit-geteilte Single-Qubit-Gates und CR_P -Paare; die eigene Erweiterung ergänzt orbit-geteilte ZZZ - und CCR_Z -Gates auf den acht Gewinnlinien, ohne die Äquivarianz zu brechen.

Daraus folgen drei Hypothesen:

1. Volles D_4 sollte gegenüber keiner Symmetrie besser generalisieren, weil es die korrekte Aufgabeninvarianz erzwingt.
2. Partielle Symmetrien, insbesondere C_4 , könnten in einigen Regimen ähnlich gut oder leicht besser sein, weil sie mehr Expressivität erhalten.
3. Der größte Gewinn könnte nicht aus weniger oder mehr Symmetrie kommen, sondern aus einer besseren äquivarianten Gatelokalisierung: Winning-Line-Gates sollten dem Modell die entscheidenden Tic-Tac-Toe-Motive direkter zugänglich machen.

Die dritte Hypothese ist die stärkste Erweiterung. Sie verschiebt den Fokus von *symmetry as parameter reduction* zu *symmetry as architecture design*. Die Frage ist dann nicht mehr nur, wie viele Parameter übrig bleiben, sondern ob die trainierbaren Interaktionen zur Kombinatorik der Aufgabe passen.

3.3 Designraum

Abbildung 1 fasst den Designraum zusammen. Panel (a) zeigt die D_4 -Symmetrie des Spielfelds. Panel (b) zeigt die Datenkodierung und die durch Untergruppen induzierten Orbits. Panel (c) zeigt den Meyer-artigen äquivarianten Gateset mit orbit-geteilten Single-Qubit-Gates und CR_P -Paaren. Panel (d) zeigt unsere winning-line-Erweiterung. Wichtig ist: Die Erweiterung ist kein symmetry breaking. Die zusätzlichen Gates werden ebenfalls über Gruppenorbits geteilt und bleiben daher äquivariant.

4 Experimentelles Protokoll

4.1 Datensatz und Labels

Wir erzeugen alle legal erreichbaren Tic-Tac-Toe-Zustände aus dem Spielbaum. Ein Spielfeld wird mit neun Positionen dargestellt:

$$\begin{array}{ccc} 0 & 1 & 2 \\ 7 & 8 & 3. \\ 6 & 5 & 4 \end{array}$$

Die Ecken sind $\{0, 2, 4, 6\}$, die Kanten $\{1, 3, 5, 7\}$, und das Zentrum ist 8. Jedes Feld hat den Wert +1 für Kreuz, -1 für Kreis und 0 für leer. Die Klassen sind Circle Win, Draw und Cross Win. Wie im Originalsetting werden auch unfertige Spiele als Draw gelabelt, weil kein Gewinner feststeht. Die Labelvektoren sind

$$y_{\text{circle}} = (+1, -1, -1), \quad y_{\text{draw}} = (-1, +1, -1), \quad y_{\text{cross}} = (-1, -1, +1).$$

Trainings- und Testsets werden pro Seed balanciert gesampelt. Die finale Auswertung verwendet 600 Testbeispiele und die Trainingsgrößen 30, 60, 120, 240, 450, 600. Wo strikt disjunkte balancierte Splits bei den größten Trainingsgrößen nicht möglich sind, wird der im CSV dokumentierte Fallback-Split konsistent verwendet.

4.2 Schaltkreis

Das Modell verwendet neun Qubits. Für jeden Datenpunkt wird auf Qubit i die Rotation

$$R_X(2\pi x_i/3) \tag{7}$$

angewendet. Diese Datenkodierung wird in jedem Layer re-uploaded. Der trainierbare Standardblock besteht aus Single-Qubit-Rotationen und gerichteten CRY-Gates. Die gerichteten Paare folgen der Brettgeometrie: Kanten zwischen benachbarten Ecken und Kantenfeldern, Kante-Zentrum-Verbindungen und Zentrum-Ecke-Verbindungen.

Die Vorhersage ist ein dreidimensionaler Erwartungswertvektor:

$$\hat{y}(x) = \left(\frac{1}{4} \sum_{i \in C} \langle Z_i \rangle, \langle Z_8 \rangle, \frac{1}{4} \sum_{i \in E} \langle Z_i \rangle \right), \tag{8}$$

wobei $C = \{0, 2, 4, 6\}$ und $E = \{1, 3, 5, 7\}$. Die vorhergesagte Klasse ist die Komponente mit dem größten Erwartungswert. Optimiert wird der Mean Squared Error zwischen $\hat{y}(x)$ und dem Labelvektor.

Sofern nicht anders angegeben, verwenden die Experimente $L = 3$ Reuploading-Layer, $p = 2$ Wiederholungen des trainierbaren Blocks pro Layer, Batchgröße 15, 30 Minibatch-Schritte pro Epoche, 100 Epochen und Adam mit Lernrate 0.01. Alle dargestellten Hauptergebnisse sind Mittelwerte über zehn Seeds mit 95%-Konfidenzintervallen.

4.3 Untergruppen und Parameterzahlen

Die sechs untersuchten Sharing-Varianten sind in Tabelle 1 dargestellt. Die Topologie des Edge-Schaltkreises bleibt dabei gleich; nur das Parameter-Sharing ändert sich. Dadurch ist der Vergleich sauberer als ein Vergleich vollständig verschiedener Schaltkreise.

Tabelle 1: Untersuchte Symmetrievarianten im Meyer-artigen Edge-Ansatz bei $L = 3, p = 2$.

Variante	Kategorie	Ordnung	Parameter
none	keine Symmetrie	1	204
Z_2 rotation	partiell	2	108
Z_2 reflection	partiell	2	126
C_4	partiell	4	60
D_2	partiell	4	78
D_4	voll	8	54

Diese Tabelle zeigt bereits einen wichtigen Punkt. Mehr Symmetrie bedeutet in diesem Ansatz weniger Parameter. Das heißt aber nicht, dass jede Verbesserung automatisch durch weniger Parameter erklärt ist. Dafür benötigen wir einen Random-Sharing-Control: Für jede symmetrieebundene Parameterzahl wird ein zufälliges, type-preserving Sharing erzeugt, das ungefähr gleich viele Parameter besitzt, aber keine Gruppenstruktur respektiert.

4.4 Winning-Line-Gates

Der Meyer-artige Edge-Ansatz verwendet lokale gerichtete Paare. Tic-Tac-Toe-Gewinne entstehen jedoch nicht aus beliebigen lokalen Paaren, sondern aus acht Dreierlinien: drei Zeilen, drei Spalten und zwei Diagonalen. Deshalb testen wir zusätzliche trainierbare Interaktionen auf diesen Triples. Die wichtigsten Familien sind:

- `line_zzz`: MultiRZ-artige ZZZ -Rotationen auf Gewinnlinien,
- `line_ccrz`: symmetrische controlled-controlled- R_Z -Interaktionen,
- `line_zzz_ccrz`: Kombination beider Line-Gates,
- `edge_line_zzz_ccrz`: Edge-Ansatz plus beide Winning-Line-Kanäle.

Auch diese Parameter werden über C_4 - oder D_4 -Orbits geteilt. Die beste Familie ist also weiterhin äquvariant; sie ist nur stärker an die Aufgabenlogik angepasst.

5 Ergebnisse

5.1 Reproduktion: volle Symmetrie generalisiert besser

Abbildung 2 zeigt die zentrale Evidenz. Die Reproduktion bestätigt die erwartete Richtung. Das unbeschränkte Edge-Modell erreicht bei 600 Trainingsbeispielen 0.627 ± 0.013 Test Accuracy. Das D_4 -äquvariante Edge-Modell erreicht 0.687 ± 0.020 . Gleichzeitig sinkt der Generalization Gap von 0.070 auf 0.021. Das freie Modell besitzt mit 204 Parametern deutlich mehr Freiheitsgrade als das D_4 -Modell mit 54 Parametern, aber diese zusätzlichen Freiheitsgrade helfen auf dem Testset nicht.

Das ist genau das Muster eines sinnvollen induktiven Bias. Die Symmetrie reduziert die Hypothesenklasse nicht beliebig, sondern in einer Weise, die zur Aufgabenstruktur passt. Das Modell muss nicht lernen, dass eine gedrehte Gewinnstellung dasselbe Label hat; diese Gleichheit ist eingebaut.




Abbildung 2: Hauptergebnisse aus dem finalen 10-Seed-Protokoll. Links: Reproduktion des Meyer-artigen Effekts, D_4 schlägt keine Symmetrie. Mitte: Untergruppen-Sweep über Trainingsgrößen 30 bis 600; C_4 folgt D_4 sehr eng. Rechts: Edge-Ansatz und Edge-plus-Line-Erweiterung über dieselbe Trainingsgrößenachse; die Winning-Line-Gates verbessern die Accuracy deutlich.

Tabelle 2: Partielle Äquivarianz im Edge-Ansatz. Werte sind mittlere Test Accuracy über zehn Seeds.

Gruppe	Parameter	Test@30	Test@600	Mean Test
none	204	0.444	0.627	0.537
Z_2 rot	108	0.495	0.667	0.585
Z_2 refl	126	0.481	0.671	0.578
C_4	60	0.552	0.695	0.631
D_2	78	0.550	0.678	0.611
D_4	54	0.532	0.687	0.632

5.2 Partielle Äquivarianz: C_4 ist konkurrenzfähig, aber kein robuster Sieger

Der Untergruppen-Sweep zeigt ein differenzierteres Bild als ein reines none-vs- D_4 -Experiment. In Tabelle 2 sind die wichtigsten Werte zusammengefasst. C_4 erreicht über alle Datenregime hinweg fast dieselbe mittlere Test Accuracy wie D_4 : 0.631 gegenüber 0.632. Bei 30 Trainingsbeispielen liegt C_4 mit 0.552 über D_4 mit 0.532; bei 120 Beispielen liegen beide nah beieinander; bei 600 Beispielen erreichen C_4 und D_4 0.695 und 0.687.

Panel (b) in Abbildung 2 zeigt diese Dynamik über die gesamte Trainingsgrößenachse. Die Interpretation sollte vorsichtig sein. Es gibt kleine Bereiche, in denen C_4 etwas besser ist. Das reicht nicht für die Aussage, dass C_4 allgemein besser sei. Es reicht aber für eine interessante praktische Aussage: Rotation-only Equivariance kann auf diesem Benchmark fast denselben Nutzen liefern wie volle D_4 -Equivariance, obwohl Spiegelungsconstraints gelockert werden. Der Nutzen der vollen Gruppe ist also nicht als binäres Dogma zu verstehen.




Abbildung 3: Controls und Ablationen aus dem finalen 10-Seed-Protokoll. Links: Parameter-matched random sharing schlägt group-orbit sharing nicht. Mitte: Ablation der Line-Gate-Familien bei 600 Trainingsbeispielen, aufsteigend nach mittlerer Leistung. Rechts: Accuracy ist nicht allein durch Parameterzahl erklärbar; task-aligned equivariant geometry verschiebt das Modell in einen anderen Leistungsbereich.

5.3 Random-Sharing-Control: Nicht nur weniger Parameter

Ein naheliegender Einwand lautet: Vielleicht hilft Symmetrie gar nicht als Struktur, sondern nur als Parameterreduktion. Dann wäre jedes zufällige Sharing mit derselben Parameterzahl ähnlich gut. Genau deshalb ist der Random-Sharing-Control wichtig. Panel (a) in Abbildung 3 zeigt, dass dieser Einwand nicht ausreicht. Bei D_4 erreicht symmetry-aware sharing 0.687, random sharing mit gleicher Parameterzahl aber nur 0.572. Bei C_4 erreicht symmetry-aware sharing 0.695, random sharing nur 0.561.

Damit wird die zentrale Interpretation stärker. Die Verbesserung kommt nicht nur daher, dass Parameter entfernt werden. Sie kommt daher, dass Parameter entlang sinnvoller geometrischer Orbits geteilt werden. Das ist die gleiche Logik wie bei Faltungen: Ein CNN ist nicht nur kleiner als ein fully connected Netzwerk; seine Gewichtsteilung entspricht einer Strukturannahme über Bilder.

5.4 Task-Aligned Equivariant Gates: der stärkste Effekt

Der deutlichste empirische Gewinn entsteht durch die winning-line gates. Panel (c) in Abbildung 2 zeigt Edge und Edge-plus-Line über dieselbe Trainingsgrößenachse. Das Meyer-artige Edge/ D_4 -Modell erreicht bei 600 Trainingsbeispielen 0.687 ± 0.020 Test Accuracy. Das beste Edge-plus-Line-Modell, `edge_line_zzz_ccrz/ $D_4$` , erreicht 0.785 ± 0.021 . Der C_4 -Ableger derselben Architektur ist mit 0.771 ± 0.019 ebenfalls stark, liegt aber im finalen Endpunkt unter D_4 .

Abbildung 3 zeigt die Ablationen. Line-Gates allein helfen teilweise, aber die beste Architektur kombiniert die ursprünglichen Edge-Interaktionen mit beiden Winning-Line-Kanälen. Das ist plausibel: Die Edge-Gates modellieren lokale Brettgeometrie und Zentrumskopplung, während die Line-Gates die tatsächlichen Gewinnmotive repräsentieren. Die Kombination gibt dem Modell sowohl lokale als auch regelnähe Struktur.

Der Parametervergleich ist wichtig. Das beste D_4 -Edge-plus-Line-Modell hat 90 Parameter, also mehr als das Edge/ D_4 -Modell mit 54 Parametern, aber immer noch deutlich weniger als der unbeschränkte Edge-Baseline mit 204 Parametern. Die Verbesserung ist also nicht einfach *mehr Parameter*. Gleichzeitig wäre es auch falsch zu sagen, dass weniger Parameter immer besser sind. Die richtige Beschreibung lautet: Die zusätzlichen Parameter liegen an der richtigen Stelle, nämlich auf äquivariant geteilten Gewinnlinien.

5.5 Deterministischer Oracle als Sanity Check

Weil Tic-Tac-Toe regelbasiert lösbar ist, haben wir zusätzlich einen deterministischen Oracle implementiert. Dieser prüft die klassischen Gewinnbedingungen direkt und erreicht auf allen 5478 legalen Zuständen 100% Accuracy bei null trainierbaren Parametern. Das ist kein konkurrierendes VQLM, sondern eine Sanity-Referenz. Es zeigt, dass die Labels eindeutig und die Aufgabe nicht intrinsisch schwierig sind. Der Abstand zwischen 0.785 und 1.00 ist daher kein Problem der Daten, sondern ein Problem der gewählten variationalen Architektur und Optimierung.

Diese Beobachtung hilft, den wissenschaftlichen Claim sauber zu formulieren. Wir zeigen nicht, dass ein Quantenmodell Tic-Tac-Toe optimal löst. Wir zeigen, dass eine bessere äquivariante Architektur einen großen Teil des Abstands zwischen dem Meyer-artigen Baseline-Ansatz und dem trivialen Regel-Oracle schließt.

6 Diskussion

6.1 Symmetrie als Designachse

Der Titel *Symmetry as a Design Axis in Variational Quantum Learning* fasst den konservativeren Claim der Experimente besser zusammen. Die Frage ist nicht nur, ob man volle D_4 -Symmetrie bewusst brechen sollte. C_4 ist kompetitiv und in kleinen Datenregimen punktuell besser, aber es schlägt D_4 nicht robust. Deshalb wäre die harte Aussage *man sollte volle Symmetrie brechen* wissenschaftlich zu stark.

Eine bessere Formulierung ist: *When to relax or redesign symmetry*. Partielle Symmetrie zeigt, dass der Symmetriegrad eine sinnvolle Modellwahlachse ist. Die winning-line-Ergebnisse zeigen aber, dass der stärkere Hebel darin liegt, die äquivariante Architektur selbst zu verbessern. Man muss D_4 nicht brechen, um D_4 zu schlagen; man kann innerhalb von D_4 bessere Gates platzieren.

6.2 Symmetrie ist nicht gleich Parameterreduktion

Die Random-Sharing-Ergebnisse sind der wichtigste Kontrollpunkt der Arbeit. Ohne sie wäre der Claim schwach. Wenn random tying mit gleicher Parameterzahl denselben Effekt hätte, dann wäre Symmetrie nur eine dekorative Erklärung für Regularisierung. Die Daten zeigen das Gegenteil. Symmetry-aware sharing ist deutlich besser als random sharing. Das spricht dafür, dass die Gruppenstruktur selbst relevant ist.

Gleichzeitig zeigen die task-aligned Line-Gates, dass Parameterzahl allein auch in die andere Richtung nicht erklärt. Das beste Modell hat mehr Parameter als Edge/ D_4 , aber weniger als edge/none. Es gewinnt nicht durch maximale Expressivität, sondern durch strukturierte Expressivität. Das ist die zentrale Lehre für Praktiker: Wenn eine Aufgabe bekannte Motive besitzt, sollte man

nicht nur Parameter teilen, sondern auch Gates so wählen, dass diese Motive als Interaktionen verfügbar sind.

6.3 Warum Winning-Line-Gates sinnvoll sind

Tic-Tac-Toe ist ein gutes Beispiel, weil die relevante Struktur offensichtlich ist. Ein Sieg entsteht aus drei gleichen Zeichen in einer Zeile, Spalte oder Diagonale. Ein rein paarbasierter Edge-Ansatz muss solche Dreiermotive indirekt darstellen. Winning-Line-Gates geben dem Modell dagegen direkte trainierbare Interaktionen auf genau diesen Triples. Das ist nicht ad hoc im schlechten Sinn, sondern task-aligned im selben Sinn, in dem eine Faltung für Bilddaten task-aligned ist: Die Architektur spiegelt die lokale Struktur des Problems wider.

Die Analogie zu klassischen Modellen ist hilfreich. Ein CNN ist nicht nur ein MLP mit weniger Parametern. Es stellt lokale, geteilte Filter bereit, die zur Bildgeometrie passen. Entsprechend ist unser Edge-plus-Line-VQLM nicht nur ein Edge-VQLM mit mehr Parametern. Es stellt äquivariant geteilte Dreierinteraktionen bereit, die zur Gewinnregel passen.

6.4 Grenzen der Ergebnisse

Die Ergebnisse bleiben finite-seed Simulationen. Die wichtigsten Sweeps verwenden zehn Seeds und ein gemeinsames Trainingsprotokoll. Außerdem ist die Architektur Meyer-artig, aber keine Byte-für-Byte-Reproduktion des Originalcodes. Die Richtung des Meyer-Effekts wird reproduziert, die absoluten Zahlen sollten jedoch als Ergebnis unserer Implementierung verstanden werden.

Eine weitere Grenze ist die Aufgabengröße. Tic-Tac-Toe ist klein und vollständig enumerierbar. Das ist für kontrollierte Experimente ein Vorteil, aber es bedeutet nicht automatisch, dass dieselbe Architekturidee auf größere Aufgaben skaliert. Der übertragbare Teil ist nicht das konkrete Winning-Line-Gate, sondern das Prinzip: Wenn eine symmetrische Aufgabe bekannte lokale oder relationale Motive besitzt, sollte ein äquivariantes VQLM diese Motive direkt als trainierbare Interaktionen anbieten.

6.5 Soft Symmetry als Ausblick

Die ursprüngliche Idee einer Soft Gate Symmetrization bleibt als Ausblick interessant. Man könnte einen Generator G in einen symmetrischen und einen symmetry-breaking Anteil zerlegen:

$$G_\alpha = \Pi_{\text{sym}}(G) + \alpha(G - \Pi_{\text{sym}}(G)), \quad \alpha \in [0, 1]. \quad (9)$$

Für $\alpha = 0$ erhält man harte Äquivarianz, für $\alpha = 1$ den freien Generator. Eine zukünftige Arbeit könnte damit kontrolliert untersuchen, ob der optimale Symmetriegrad mit einem künstlich eingeführten Symmetriebruch wandert.

Die aktuellen Resultate zeigen jedoch, dass vor dieser kontinuierlichen Frage bereits eine architektonische Frage steht. Wenn ein hart äquivariantes Modell schlecht genug ist, kann der Grund nicht nur zu viel Symmetrie sein. Der Grund kann auch sein, dass die falschen äquivarianten Interaktionen angeboten werden. Genau das legt der Gewinn der Winning-Line-Gates nahe.

7 Fazit

Diese Arbeit rekonstruiert Meyer et al. als Ausgangspunkt für eine breitere Sicht auf Symmetrie in Variational Quantum Learning. Die Reproduktion bestätigt qualitativ: volle D_4 -Äquivarianz verbessert die Test Accuracy gegenüber keiner Symmetrie und reduziert den Generalization Gap. Die Untergruppenexperimente zeigen, dass partielle Äquivarianz eine sinnvolle Modellwahlachse ist; insbesondere C_4 erreicht fast dieselbe Leistung wie D_4 , ohne robust besser zu sein. Der Random-Sharing-Control zeigt, dass der Effekt nicht bloß durch weniger Parameter erklärt werden kann.

Der wichtigste neue Befund ist die task-aligned äquivariante Architektur. Durch zusätzliche Gates auf den acht Gewinnlinien steigt die Test Accuracy im besten D_4 -Modell bei 600 Trainingsbeispielen von 0.687 auf 0.785. Das Modell bleibt dabei äquivariant. Der stärkste Claim ist daher nicht, dass man Symmetrie brechen muss. Der stärkste Claim ist: Sobald Symmetrie eingebaut ist, sollte man den äquivarianten Designraum weiter nutzen, um Gates an die Struktur der Aufgabe anzupassen.

Für zukünftige VQLM-Benchmarks ergibt sich daraus eine konkrete Empfehlung. Eine bekannte Symmetrie sollte nicht nur als Parameter-Sharing-Regel verwendet werden. Sie sollte als Sprache dienen, in der man task-aligned Gates konstruiert: lokale Motive, relationale Muster, konservierte Größen oder kombinatorische Substrukturen. In diesem Sinn erweitert die Arbeit Meyer et al. natürlich: Meyer et al. zeigen, dass Symmetrie hilft; diese Arbeit zeigt, dass die Wahl der symmetrieverträglichen Interaktionen mindestens ebenso wichtig sein kann.

Formale Angaben

Wortanzahl fachlicher Haupttext: **3363**

Zeichenanzahl ohne Leerzeichen: **21350**

Zeichenanzahl mit Leerzeichen: **24604**

Hinweis: Die Wortzählung bezieht sich auf den fachlichen Haupttext in `contents.tex` bis einschließlich Fazit und wurde mit `texcount` bestimmt. Die Zeichenzählung ist eine bereinigte Näherung ohne LaTeX-Kommandos, Literaturbefehle, Tabellenkörper und Gleichungen.

Eigenständigkeitserklärung

Hiermit bestätige ich, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Hilfsmittel benutzt habe. Die Stellen der Arbeit, die dem Wortlaut oder dem Sinn nach anderen Werken entnommen sind, wurden unter Angabe der Quelle kenntlich gemacht.

Unterschrift

Literatur

- [1] Marcello Benedetti, Erika Lloyd, Stefan Sack, and Mattia Fiorentini. Parameterized quantum circuits as machine learning models. *Quantum Science and Technology*, 4(4):043001, 2019.
- [2] Kishor Bharti, Alba Cervera-Lierta, Thi Ha Kyaw, Tobias Haug, Sumner Alperin-Lea, Abhinav Anand, Matthias Degroote, Hermann Heimonen, Jakob S. Kottmann, Tim Menke, et al. Noisy intermediate-scale quantum algorithms. *Reviews of Modern Physics*, 94(1):015004, 2022.
- [3] Michael M. Bronstein, Joan Bruna, Taco Cohen, and Petar Veličković. Geometric deep learning: Grids, groups, graphs, geodesics, and gauges. *arXiv preprint arXiv:2104.13478*, 2021.
- [4] Taco S. Cohen and Max Welling. Group equivariant convolutional networks. In *Proceedings of the 33rd International Conference on Machine Learning*, pages 2990–2999, 2016.
- [5] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- [6] Jarrod R. McClean, Sergio Boixo, Vadim N. Smelyanskiy, Ryan Babbush, and Hartmut Neven. Barren plateaus in quantum neural network training landscapes. *Nature Communications*, 9:4812, 2018.
- [7] Johannes Jakob Meyer, Marian Mularski, Elies Gil-Fuster, Antonio Anna Mele, Francesco Arzani, Alissa Wilms, and Jens Eisert. Exploiting symmetry in variational quantum machine learning. *arXiv preprint arXiv:2205.06217*, 2022.
- [8] Adrián Pérez-Salinas, Alba Cervera-Lierta, Elies Gil-Fuster, and José I. Latorre. Data re-uploading for a universal quantum classifier. *Quantum*, 4:226, 2020.
- [9] Arthur Pesah, Marco Cerezo, Samson Wang, Tyler Volkoff, Andrew T. Sornborger, and Patrick J. Coles. Absence of barren plateaus in quantum convolutional neural networks. *Physical Review X*, 11(4):041011, 2021.
- [10] John Preskill. Quantum computing in the nisq era and beyond. *Quantum*, 2:79, 2018.
- [11] Maria Schuld, Alex Bocharov, Krysta M. Svore, and Nathan Wiebe. Circuit-centric quantum classifiers. *Physical Review A*, 101(3):032308, 2020.
- [12] Manzil Zaheer, Satwik Kottur, Siamak Ravanbakhsh, Barnabas Poczos, Ruslan Salakhutdinov, and Alexander Smola. Deep sets. In *Advances in Neural Information Processing Systems*, volume 30, 2017.